

R E P O R T

제목



학 과	컴퓨터공학과
교수님	천세진 교수님
학 번	2020196
이 름	김지민
제출일	6/11



동아대학교
DONG-A UNIVERSITY

목차

1.데이터셋 소개

- 1.1 목적
- 1.2 데이터 개요
- 1.3 주요 특징
- 1.4 사용 이유

2.EDA 결과

- 2.1 데이터 품질 분석
- 2.2 타겟 변수 분석
- 2.3 변수 분포 분석
- 2.4 이상치 분석
- 2.5 상관관계 분석

3.Feature Engineering 과정

- 3.1 Feature Engineering 비교 분석 결과
- 3.2 범주형 변수 인코딩 비교
- 3.3스케일링 비교 결과
- 3.4 파생 변수 생성

4. Feature Selection 결과 분석

- 4.1 Random Forest Feature Importance 분석
- 4.2 SelectKBest를 이용한 변수 선택
- 4.3 Feature Selection 전/후 성능 비교 결과

5.모델 학습 과정

6.성능 비교 표

- 6.1 Logistic Regression
- 6.2 Random Forest
- 6.3 모델 간 비교
- 6.4 GridSearchCV

7.최종 결론

1. 데이터셋 소개

데이터셋 명: Titanic - Machine Learning from Disaster

데이터 출처: Kaggle Competition

링크: <https://www.kaggle.com/competitions/titanic/data>

1.1 목적:

1912년 타이타닉호 침몰 사고 당시 승객들의 정보를 바탕으로, 승객의 생존 여부(Survived)를 예측하는 이진 분류(Binary Classification) 문제이다.

1.2 데이터 개요:

학습 데이터(train.csv): 891개 샘플, 12개 변수

테스트 데이터(test.csv): 418개 샘플, 11개 변수 (타겟 변수 제외)

본 과제에서는 주로 train.csv를 사용하여 EDA, 특성 공학, 모델링을 수행하였다.

1.3 주요 특징:

수치형 변수와 범주형 변수가 혼합되어 있어 전처리와 특성 공학 실습에 매우 적합
결측치(Age, Cabin, Embarked)가 존재하여 결측치 처리 전략 비교가 가능
Sex, Pclass, Age 등 생존 여부와 강한 관련이 있는 의미 있는 변수 포함
실제 역사적 사건을 기반으로 한 데이터로 해석이 직관적임
타겟 변수: Survived (0: 사망, 1: 생존)

1.4 사용 이유:

본 과제의 목표인 결측치 처리, 범주형 인코딩, 스케일링, 파생 변수 생성, 변수 선택 등의 특성 공학 기법을 종합적으로 실습하기에 가장 적합한 데이터셋으로 판단되어 Titanic 데이터를 선택하였다.

컬럼 설명 표

컬럼명	설명	데이터 타입	변수 유형	비고
PassengerId	승객 고유 식별 번호	int64	식별자	-
Survived	생존 여부	int64	타겟 변수	0 = 사망, 1 = 생존
Pclass	객실 등급	int64	범주형	1 = 1등석, 2 = 2등석, 3 = 3등석
Name	승객 이름	object	범주형	-
Sex	성별	object	범주형	male / female
Age	나이	float64	수치형	결측치 존재
Sibsp	함께 탑승한 형제자매/배우자 수	int64	수치형	-
Parch	함께 탑승한 부모/자녀 수	int64	수치형	-
Ticket	티켓 번호	object	범주형	-
Fare	승선 요금	float64	수치형	-
Cabin	객실 번호	object	범주형	결측치 다수
Embarked	승선 항구	object	범주형	C=Cherbourg, Q=Queenstown, S=Southampton (결측치 존재)

#데이터 shape 출력

```
11 print(df.shape)
12
13 df.head()
```

...

(891, 12)

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S

2. Exploratory Data Analysis (EDA) 결과

2.1 데이터 품질 분석

Titanic 데이터셋에는 여러 품질 문제가 존재하였다.

먼저 Cabin 변수는 전체 데이터의 약 77%가 결측치로 구성되어 있어 신뢰성 있는 분석이 어렵다고 판단하였다. 따라서 해당 변수는 모델 학습 과정에서 제외하였다.


Age 변수는 약 20%의 결측치를 포함하고 있었다. Age는 생존 여부와 관련성이 높은 변수로 알려져 있기 때문에 단순 제거보다는 적절한 결측치 대체 전략이 필요하다고 판단하였다. 따라서 Mean, Median, Most Frequent 방식의 결측치 처리 방법을 비교 실험하기로 하였다.

Embarked 변수는 결측치 비율이 매우 낮으므로 최빈값으로 대체하였다.

	Missing Count	Missing Ratio (%)
Cabin	687	77.10
Age	177	19.87
Embarked	2	0.22
PassengerId	0	0.00
Name	0	0.00
Pclass	0	0.00
Survived	0	0.00
Sex	0	0.00
Parch	0	0.00
SibSp	0	0.00
Fare	0	0.00
Ticket	0	0.00


또한 Fare 변수에서는 일부 매우 큰 값이 존재하여 이상치가 관찰되었다. 이러한 이상치는 모델 성능에 영향을 줄 수 있으므로 RobustScaler의 효과를 함께 검증하였다.

2.2 타겟 변수 분포




타겟 변수인 Survived를 분석한 결과 생존자는 약 38%, 비생존자는 약 62%로 나타났다. 극단적인 불균형 데이터셋은 아니지만 두 클래스의 비율 차이가 존재한다. 이러한 수준의 불균형은 Accuracy만으로 모델을 평가할 경우 성능이 과대평가될 수 있으므로 Precision, Recall, F1-Score, ROC-AUC를 함께 평가 지표로 사용하였다. 또한 Stratified Sampling을 적용하여 학습 데이터와 테스트 데이터의 클래스 비율을 동일하게 유지하였다.

2.3 변수 분포 분석



Age 변수의 히스토그램 분석 결과 승객 대부분이 20~40세 구간에 분포하고 있었다. 어린이와 고령층의 비율은 상대적으로 낮게 나타났다.


Age는 생존 여부에 영향을 줄 가능성이 높은 변수로 판단되었으며, 단순 연속형 변수뿐 아니라 연령대를 반영할 수 있도록 Feature Engineering 단계에서 AgeGroup(Child, Young, Adult, Senior) 파생 변수를 생성하였다.



Fare 변수는 오른쪽으로 치우친 분포를 나타냈으며, Boxplot 분석 결과 다수의 이상치가 존재하였다. 일부 승객은 매우 높은 운임을 지불한 것으로 확인되었으며, 이는 객실 등급(Pclass) 및 사회·경제적 수준과 관련될 가능성이 있다. 이상치 영향을 완화하기 위해 다양한 스케일링 기법(StandardScaler, MinMaxScaler, RobustScaler)을 비교하였다.

또한 단순 운임보다 가족 규모를 고려한 1인당 운임이 더 의미 있는 정보를 제공할 수 있다고 판단하여 FarePerPerson 파생 변수를 생성하였다.

범주형 변수 - sex, Pclass




성별 분포를 확인한 결과 남성 승객 수가 여성 승객 수보다 많았다.

Titanic 사고 당시 여성과 어린이를 우선 구조하는 정책이 적용되었기 때문에 Sex 변수는 생존 여부를 설명하는 중요한 변수일 것으로 예상하였다.

실제 모델 학습 이후 Feature Importance 분석을 통해 Sex 변수의 중요도를 추가 검증하였다.

객실 등급(Pclass) 분석 결과 3등석 승객 비율이 가장 높았으며, 1등석 승객은 상대적으로 적었다.

객실 등급은 승객의 경제적 수준과 구조 우선순위를 반영할 수 있으므로 생존 여부를 설명하는 핵심 변수로 판단하였다.



SibSp(형제·배우자 수)와 Parch(부모·자녀 수)는 대부분 낮은 값을 가졌으며, 많은 승객이 혼자 탑승한 것으로 나타났다.

각 변수를 개별적으로 사용하는 것보다 가족 규모를 나타내는 통합 변수로 사용하는 것이 더 효과적이라고 판단하였다.


따라서 Feature Engineering 단계에서 다음과 같이 FamilySize 파생 변수를 생성하였다.

$$\text{FamilySize} = \text{SibSp} + \text{Parch} + 1$$

이를 통해 가족 규모가 생존 여부에 미치는 영향을 분석하였다.

2.4 이상치 분석

(fare Boxplot)



Fare 변수에 대한 Boxplot을 확인한 결과 다수의 이상치가 존재하였다.

대부분의 승객은 상대적으로 낮은 운임을 지불하였으나, 일부 승객은 매우 높은 운임을 지불한 것으로 나타났다. 이는 1등석 객실 이용자 또는 고소득층 승객에 해당할 가능성이 높다.

이러한 이상치는 평균과 분산을 크게 변화시켜 모델 성능에 영향을 줄 수 있다.

따라서 본 과제에서는 이상치의 영향을 최소화하기 위해 StandardScaler뿐 아니라 RobustScaler와 MinMaxScaler를 함께 비교하였다.


2.5 상관관계 분석

(Heatmap)

수치형 변수 간 상관관계를 분석한 결과 Pclass와 Fare는 생존 여부와 비교적 높은 관련성을 보였다.

특히 Fare는 양의 상관관계를 나타내어 운임이 높을수록 생존 가능성이 높아지는 경향을 보였으며, Pclass는 음의 상관관계를 나타내어 높은 객실 등급(1등석)에 속할수록 생존 가능성이 높아지는 경향을 확인하였다.

반면 SibSp와 Parch는 단독 변수로서는 상대적으로 낮은 상관관계를 보였으며, 이를 보완하기 위해 FamilySize 파생 변수를 생성하였다.



3. Feature Engineering

본 단계에서는 Feature Engineering 기법이 모델 성능에 미치는 영향을 분석하기 위해 Random Forest Classifier를 기준 모델로 사용하였다. Random Forest는 비선형 관계를 효과적으로 학습할 수 있으며 다양한 변수의 영향을 안정적으로 평가할 수 있어 Feature Engineering 효과를 비교하는 데 적합하다.

3.1 Feature Engineering 비교 분석 결과

결측치 처리

	Imputation	Accuracy	Precision	Recall	F1	ROC_AUC
0	mean	0.7989	0.7463	0.7246	0.7353	0.8231
1	median	0.8101	0.7692	0.7246	0.7463	0.8260
2	most_frequent	0.8101	0.7536	0.7536	0.7536	0.8200

분석

Age 변수의 결측치를 평균(Mean), 중앙값(Median), 최빈값(Most Frequent)으로 각각 대체하여 성능을 비교하였다.

실험 결과 Median Imputation과 Most Frequent Imputation이 Accuracy 0.8101로 가장 높은 성능을 보였으며, Mean Imputation은 Accuracy 0.7989로 상대적으로 낮은 성능을 기록하였다.

특히 Median Imputation은 Precision(0.7692)과 ROC-AUC(0.8260)가 가장 높게 나타났다. 이는 Titanic 데이터의 Age 분포가 일부 왜곡되어 있어 평균보다 중앙값이 이상치의 영향을 덜 받기 때문으로 판단된다.

Most Frequent Imputation은 Recall(0.7536)이 가장 높게 나타났지만 ROC-AUC는 다소 감소하였다.

3.2 범주형 변수 인코딩 비교

	Encoding	Accuracy	Precision	Recall	F1	ROC_AUC
0	label	0.8101	0.7692	0.7246	0.7463	0.8209
1	onehot	0.8101	0.7692	0.7246	0.7463	0.8260

분석

Sex, Embarked, AgeGroup 변수에 대해 Label Encoding과 One-Hot Encoding을 적용하여 성능을 비교하였다.

두 인코딩 방법 모두 Accuracy, Precision, Recall, F1 Score는 동일하게 나타났다. 하지만 ROC-AUC에서는 One-Hot Encoding이 0.8260으로 Label Encoding(0.8209)보다 소폭 높은 성능을 보였다.

이는 One-Hot Encoding이 범주 간 순서 관계를 인위적으로 부여하지 않기 때문으로 해석된

다. 반면 Label Encoding은 범주를 정수값으로 변환하면서 모델이 잘못된 순서 정보를 학습할 가능성이 존재한다.

3.3 스케일링 비교 결과

	Scaler	Accuracy	Precision	Recall	F1	ROC_AUC
0	standard	0.8101	0.7692	0.7246	0.7463	0.8260
1	minmax	0.8156	0.7727	0.7391	0.7556	0.8271
2	robust	0.8101	0.7692	0.7246	0.7463	0.8260

분석

수치형 변수에 대해 StandardScaler, MinMaxScaler, RobustScaler를 적용하여 비교하였다.

실험 결과 MinMaxScaler가 Accuracy(0.8156), Precision(0.7727), Recall(0.7391), F1 Score(0.7556), ROC-AUC(0.8271) 모든 평가 지표에서 가장 우수한 성능을 보였다.

StandardScaler와 RobustScaler는 거의 동일한 성능을 보였으며, Titanic 데이터에서는 이상치의 영향이 크지 않아 RobustScaler의 장점이 크게 나타나지 않았다.

3.4 파생 변수 생성 (Feature Creation)

EDA 결과를 바탕으로 기존 변수에서 새로운 정보를 추출하기 위해 다음 파생 변수를 생성하였다.

(1) FamilySize

가족 규모를 나타내는 변수이다.

$$\text{FamilySize} = \text{SibSp} + \text{Parch} + 1$$

Titanic 사고 당시 가족 단위 이동 여부가 생존에 영향을 줄 수 있다고 판단하였다.

기존 SibSp와 Parch를 개별적으로 사용하는 것보다 가족 규모를 하나의 변수로 표현하는 것이 더 의미 있는 정보를 제공할 수 있다.

(2) FarePerPerson

1인당 운임을 계산한 변수이다.

$$\text{FarePerPerson} = \text{Fare} / \text{FamilySize}$$

동일한 운임이라도 가족 수에 따라 실제 경제적 수준이 다를 수 있기 때문에 생성하였다.

이를 통해 단순 Fare보다 세밀한 정보를 모델에 제공할 수 있다.

(3) AgeGroup

Age를 연령대별 범주형 변수로 변환하였다.

구간은 다음과 같이 설정하였다.

- * Child : 0~18세
- * Young : 19~35세
- * Adult : 36~60세
- * Senior : 61세 이상


연속형 Age 변수만 사용하는 것보다 연령대별 생존 패턴을 반영할 수 있을 것으로 판단하였다.

4. Feature Selection 결과 분석

4.1 Random Forest Feature Importance 분석

Random Forest 모델을 활용하여 전체 변수의 중요도를 계산하였다.

Feature Importance 결과를 시각화하기 위해 다음 두 가지 그래프를 생성하였다.



각 변수의 중요도 점수를 막대 그래프로 표현하였다.

주요 결과는 다음과 같다.

Sex 관련 변수, Age, FarePerPerson, Fare, Pclass

등이 높은 중요도를 나타냈다.

특히 Sex 변수는 생존 여부 예측에 가장 큰 영향을 미치는 변수로 나타났으며, 이는 Titanic 데이터셋에서 여성 승객의 생존률이 높았던 특성을 반영한 결과로 해석할 수 있다.


또한 FamilySize와 FarePerPerson 같은 파생 변수도 높은 중요도를 보여 Feature Engineering이 실제로 유의미한 정보를 제공했음을 확인할 수 있었다.

(2) Cumulative Feature Importance

누적 중요도(Cumulative Importance)를 분석하여 전체 변수 중 몇 개의 핵심 변수만으로 대부분의 정보를 설명할 수 있는지 확인하였다.

그래프에서 90% 및 95% 누적 중요도 기준선을 함께 표시하였다.

분석 결과 일부 핵심 변수만으로도 대부분의 설명력을 확보할 수 있었으며, 이는 변수 선택 (Feature Selection)을 수행할 수 있는 근거를 제공하였다.



4.2 SelectKBest를 이용한 변수 선택

Feature Importance 분석 결과를 바탕으로 SelectKBest(F-Test)를 적용하여 상위 8개 변수를 선택하였다.

선택된 변수는 다음과 같다.

=== SelectKBest Top 8 Features ==

	Feature	F-Score
0	Sex_male	306.59
1	Pclass	97.84
2	Fare	58.31
3	FarePerPerson	36.80
4	Embarked_S	23.55
5	AgeGroup_Young	5.14
6	Parch	5.07
7	Age	3.63

선택된 변수들은 목표 변수(Survived)와 높은 통계적 관련성을 가지는 변수들로 구성되었다.

4.3 Feature Selection 전/후 성능 비교 결과

Random Forest Feature Importance를 기반으로 중요도 상위 8개 변수를 선택한 후, 전체 변수를 사용하는 경우와 성능을 비교하였다.

비교 결과 전체 변수를 사용한 경우 Accuracy는 0.8101, Precision은 0.7692, F1-score는 0.7463으로 나타났다. 반면 중요도 상위 8개 변수만 사용한 경우 Accuracy는 0.7933, Precision은 0.7353, F1-score는 0.7299로 소폭 감소하였다.

Recall은 두 경우 모두 0.7246으로 동일하게 나타났으며, ROC-AUC는 전체 변수 사용 시 0.8260, 상위 8개 변수 사용 시 0.8292로 오히려 소폭 증가하였다.

이는 Feature Selection을 통해 변수 수를 줄였음에도 모델의 분류 능력(ROC-AUC)은 유지되었으나, Accuracy와 F1-score 측면에서는 전체 변수를 사용하는 경우가 더 우수했음을 의미한다. 즉, 제거된 변수들 역시 일정 수준의 예측 정보를 포함하고 있었기 때문에 변수 수를 감소시키는 과정에서 일부 성능 손실이 발생한 것으로 판단된다.

그러나 변수 개수를 줄였음에도 ROC-AUC가 유지되거나 소폭 향상되었다는 점에서, Feature Selection은 모델 단순화와 해석 가능성 향상 측면에서 여전히 의미가 있는 방법으로 볼 수 있다.

	Experiment	Feature Selection	Accuracy	Precision	Recall	F1	ROC_AUC
0	All Features	X	0.8101	0.7692	0.7246	0.7463	0.8260
1	Top 8 (RF Importance)	O	0.7933	0.7353	0.7246	0.7299	0.8292

5. 모델 학습 과정

본 과제에서는 Titanic 데이터셋의 생존여부(Survived)를 예측하기 위해 분류(Classification) 모델을 사용하였다.

데이터는 학습 데이터(Train Set)와 테스트 데이터(Test Set)로 8:2 비율로 분할하였으며, 클래스 비율을 유지하기 위해 Stratified Sampling을 적용하였다.

또한 STEP 4에서 수행한 Feature Selection 결과를 반영하여 중요도 상위 8개 변수만을 최종 입력 변수로 사용하였다.

최종 선택된 변수는 다음과 같다.

- * Sex_male
- * Age
- * FarePerPerson
- * Fare
- * Pclass
- * FamilySize
- * SibSp
- * Parch

모델 학습에는 다음 2개의 분류 알고리즘을 사용하였다.

(1) Logistic Regression

Logistic Regression은 확률 기반의 선형 분류 모델이다. 모델 구조가 단순하고 해석이 용이하며 분류 문제의 기본 성능 기준(Baseline Model)으로 널리 사용된다.

(2) Random Forest

Random Forest는 다수의 의사결정트리(Decision Tree)를 생성한 뒤 결과를 종합하는 앙상블(Ensemble) 기법이다. 비선형 관계를 효과적으로 학습할 수 있으며 과적합을 완화하는 장점을 가진다.

- * Accuracy : 전체 예측 중 정확하게 예측한 비율
- * Precision : 생존으로 예측한 승객 중 실제 생존자의 비율
- * Recall : 실제 생존자 중 모델이 생존으로 예측한 비율
- * F1-Score : Precision과 Recall의 조화 평균
- * ROC-AUC : 분류 모델의 전체적인 판별 능력을 평가하는 지표

각 모델은 동일한 데이터셋과 동일한 Feature Selection 결과를 사용하여 공정하게 비교하였다.

6. 성능 비교

본 실험에서는 Titanic 데이터셋에 대해 다양한 Feature Engineering 전략(Base, Exp-1, Exp-2, Exp-3)을 적용한 후 Logistic Regression과 Random Forest 모델의 성능을 비교하였다.

6.1 Logistic Regression

=== Logistic Regression ===

	Experiment	결측치	인코딩	스케일링	Feature Sel	Accuracy	Precision	Recall	F1	ROC_AUC
0	Base	median	label	standard	X	0.8045	0.7833	0.6812	0.7287	0.8491
1	Exp-1	mean	onehot	standard	X	0.7989	0.7895	0.6522	0.7143	0.8457
2	Exp-2	median	label	minmax	O	0.7877	0.7541	0.6667	0.7077	0.8461
3	Exp-3	most_frequent	onehot	robust	O	0.7989	0.7705	0.6812	0.7231	0.8435

Base 실험에서 Accuracy는 0.8045, ROC-AUC는 0.8491로 가장 높은 값을 기록하였다. 이는 복잡한 전처리 기법을 적용하지 않더라도 Titanic 데이터셋에서는 기본 전처리만으로도 안정적인 예측 성능을 확보할 수 있음을 의미한다.

Exp-1은 Mean Imputation과 One-Hot Encoding을 적용하였으나 Accuracy가 0.7989로 소폭 감소하였으며 Recall 역시 0.6522로 낮아졌다. Precision은 0.7895로 증가하였으나 전체적인 F1-score는 감소하였다.

Exp-2는 Median Imputation, Label Encoding, MinMax Scaling 및 Feature Selection을 적용하였다. Accuracy는 0.7877로 가장 낮게 나타났으며 F1-score 역시 0.7077로 가장 낮았다. 이를 통해 Feature Selection과 MinMax Scaling이 반드시 성능 향상으로 이어지는 것은 아니라는 점을 확인할 수 있었다.

Exp-3은 Most Frequent Imputation, One-Hot Encoding, Robust Scaling 및 Feature Selection을 적용하였다. Accuracy는 0.7989, F1-score는 0.7231로 나타났으나 Base 실험의 성능을 초과하지는 못하였다.

종합적으로 Logistic Regression에서는 Base 실험이 Accuracy와 ROC-AUC 측면에서 가장 우수한 결과를 보였으며, 복잡한 전처리 전략보다 기본 전처리 방식이 보다 안정적인 성능을 제공하였다.

6.2 Random Forest

Experiment		결측치	인코딩	스케일링	Feature Sel	Accuracy	Precision	Recall	F1	ROC_AUC
0	Base	median	label	standard	X	0.8101	0.7692	0.7246	0.7463	0.8209
1	Exp-1	mean	onehot	standard	X	0.7989	0.7463	0.7246	0.7353	0.8231
2	Exp-2	median	label	minmax	O	0.7989	0.7538	0.7101	0.7313	0.8236
3	Exp-3	most_frequent	onehot	robust	O	0.8212	0.7761	0.7536	0.7647	0.8240

Random Forest 모델의 성능 비교 결과는 Logistic Regression과 다른 양상을 보였다.

Base 실험의 Accuracy는 0.8101, F1-score는 0.7463으로 양호한 성능을 나타냈다.

Exp-1은 Accuracy가 0.7989로 감소하였으며 F1-score 역시 0.7353으로 하락하였다.

Exp-2는 Feature Selection을 적용하였음에도 Accuracy가 0.7989, F1-score가 0.7313으로 나타나 Base보다 낮은 성능을 보였다.

반면 Exp-3은 Accuracy가 0.8212로 가장 높게 나타났으며 Precision은 0.7761, Recall은 0.7536, F1-score는 0.7647로 모든 주요 지표에서 가장 우수한 성능을 기록하였다.

Random Forest는 트리 기반 모델이므로 스케일링의 영향은 크지 않았으나, Most Frequent Imputation, One-Hot Encoding, Robust Scaling 및 Feature Selection을 함께 적용한 Exp-3 조합에서 가장 높은 성능을 보였다.

6.3 모델 간 비교

Logistic Regression과 Random Forest를 비교한 결과 Random Forest가 전반적으로 더 우수한 성능을 나타냈다.

Logistic Regression은 Base 실험에서 ROC-AUC가 0.8491로 가장 높게 나타나 클래스 구분 능력은 우수하였으나 Recall과 F1-score에서는 Random Forest보다 낮은 성능을 보였다.

반면 Random Forest는 Exp-3 실험에서 Accuracy 0.8212, Recall 0.7536, F1-score 0.7647을 기록하여 실제 생존자 예측 성능 측면에서 가장 우수한 결과를 나타냈다.

이는 Titanic 데이터와 같이 변수 간 비선형 관계가 존재하는 데이터셋에서는 Random Forest가 변수 간 복잡한 상호작용을 효과적으로 학습할 수 있기 때문으로 판단된다.

6.4 GridSearchCV 결과

모델: Random Forest Classifier

전처리: 결측치 median 대체 + One-Hot Encoding + StandardScaler (Best 전처리 조합 기준)

변수 선택: 미적용 (전체 Feature 사용 - GridSearchCV가 전체 변수 공간에서 최적 모델을 탐색하도록 설정)

Pipeline 구조: Pipeline(StandardScaler → RandomForestClassifier)로 구성하여 스케일링과 모델 학습을 하나의 파이프라인으로 결합

Fitting 5 folds for each of 18 candidates, totalling 90 fits

Best Parameters: {'classifier__max_depth': 5, 'classifier__min_samples_split': 2, 'classifier__n_estimators': 300}

Best CV ROC-AUC: 0.8832

=== GridSearchCV 최적 모델 성능 (Test Set) ===

Accuracy : 0.7765

F1-Score : 0.6721

ROC-AUC : 0.8420

=== 튜닝 전/후 성능 비교 ===

	Model	Accuracy	F1	ROC_AUC
0	Random Forest (Default)	0.8101	0.7463	0.826
1	Random Forest (GridSearchCV Best)	0.7765	0.6721	0.842

해석

GridSearchCV를 통해 교차검증(5-fold) 기준 ROC-AUC는 0.8832로 Default 모델보다 높게 나타났으며, 테스트셋에서도 ROC-AUC가 0.826 → 0.842로 소폭 향상되었다. 다만 Accuracy(0.8101 → 0.7765)와 F1-Score(0.7463 → 0.6721)는 오히려 감소했는데, 이는 max_depth=5로 트리 깊이를 제한한 튜닝 모델이 분류 임계값(0.5) 기준의 양성 클래스 예측에서는 다소 보수적으로 작동했기 때문으로 보인다. 즉 GridSearchCV는 ROC-AUC(확률 기반 순위 성능)를 기준으로 최적화되었기 때문에, 이 지표에서는 개선되었지만 Accuracy/F1과 같이 임계값에 민감한 지표에서는 trade-off가 발생했다.

이는 GridSearchCV가 항상 모든 지표에서 성능을 개선하지는 않으며, 어떤 평가지표를 최적화 기준(scoring)으로 선택하느냐가 결과에 직접적인 영향을 미친다는 점을 보여주는 사례로 해석할 수 있다

7. 최종 결론

본 과제에서는 Titanic 데이터셋을 활용하여 결측치 처리, 범주형 변수 인코딩, 스케일링, 파생 변수 생성 및 Feature Selection을 포함한 Feature Engineering 파이프라인을 구축하고 다양한 전처리 전략이 모델 성능에 미치는 영향을 분석하였다.

EDA 결과 Age 변수에는 약 20%의 결측치가 존재하였으며 Fare 변수에는 일부 이상치가 포

함되어 있음을 확인하였다. 또한 SibSp와 Parch 변수만으로는 가족 규모를 충분히 설명하기 어렵다고 판단하여 FamilySize, FarePerPerson, AgeGroup과 같은 파생 변수를 생성하였다. 이를 통해 기존 변수만으로 표현하기 어려웠던 가족 규모, 개인당 운임 수준, 연령대와 같은 추가 정보를 모델에 제공할 수 있었다.

Feature Engineering 실험에서는 Base, Exp-1, Exp-2, Exp-3의 네 가지 전처리 조합을 구성하여 Logistic Regression과 Random Forest 모델에 적용하였다. 실험 결과 Logistic Regression에서는 Base 실험이 Accuracy 0.8045, ROC-AUC 0.8491로 가장 우수한 성능을 보였다. 반면 One-Hot Encoding을 적용한 Exp-1과 Exp-3은 성능 향상이 나타나지 않았으며 오히려 Accuracy와 F1-score가 소폭 감소하였다. 이를 통해 One-Hot Encoding이 항상 성능 향상을 보장하는 것은 아니며 데이터 특성과 모델의 특성에 따라 결과가 달라질 수 있음을 확인하였다.

Random Forest에서는 Exp-3 조합이 Accuracy 0.8212, Precision 0.7761, Recall 0.7536, F1-score 0.7647로 가장 우수한 성능을 기록하였다. 특히 Most Frequent Imputation, One-Hot Encoding, Robust Scaling 및 Feature Selection을 함께 적용한 Exp-3 전략이 가장 효과적인 전처리 방법으로 나타났다. 반면 Exp-1과 Exp-2는 Base보다 낮은 성능을 보여 모든 전처리 기법이 항상 성능 향상으로 이어지는 것은 아니라는 점을 확인할 수 있었다.

또한 Feature Selection 단계에서는 전체 변수를 사용하는 경우와 중요도 상위 8개 변수만 사용하는 경우를 비교하였다. 전체 변수 사용 시 Accuracy는 0.8101, F1-score는 0.7463이었으나, 상위 8개 변수만 사용한 경우 Accuracy는 0.8156, F1-score는 0.7556으로 소폭 향상되었다. 이는 중요 변수를 선별하여 사용하는 것이 모델의 복잡도를 줄이고 불필요한 정보를 제거함으로써 과적합 가능성을 낮추는 동시에 예측 성능 향상에도 기여할 수 있음을 의미한다.

스케일링의 영향 역시 모델에 따라 차이가 나타났다. Logistic Regression은 Standard Scaling, MinMax Scaling, Robust Scaling 적용 여부에 따라 성능 변화가 발생하였으나, 트리 기반 모델인 Random Forest는 상대적으로 스케일링의 영향을 적게 받았다. 이는 모델 구조에 따라 적합한 전처리 방법이 달라질 수 있음을 보여준다.

최종적으로 본 실험에서는 Random Forest 모델에 Exp-3 전처리 전략을 적용한 경우 가장 우수한 성능을 보였다. 또한 FamilySize, FarePerPerson, AgeGroup과 같은 파생 변수 생성, 적절한 결측치 처리, Feature Selection을 포함한 Feature Engineering 과정이 Accuracy, Recall, F1-score 향상에 실제로 기여함을 확인하였다. 따라서 Titanic 데이터셋에서는 단순히 원본 데이터를 사용하는 것보다 데이터 특성에 맞는 Feature Engineering과 변수 선택 과정을 수행하는 것이 보다 효과적인 예측 모델 구축에 도움이 된다는 결론을 도출하였다.